OSD 读写源码分析

1日志

ceph版本: https://github.com/ceph/ceph/tree/v18.2.1

```
1 $ git log --pretty=oneline
2 7fe91d5d5842e04be3b4f514d6dd990c54b29c76 (HEAD, tag: v18.2.1) 18.2.1
```

ceph中日志机制很高级,比如源码中是这样描述的:


实际输出却是:

在__func__前面,时间戳、线程号、日志级别、pg等,都是动态添加进去的。


```
1 # 这个函数就添加了pg信息的日志前缀,具体是怎么做到的以后再看
2 template <typename T>
3 static ostream& _prefix(std::ostream *_dout, T *pg) {
4   return pg->gen_prefix(*_dout);
5 }
```


2 总览


2.1 OSD读写类图



2.2 主要流程








3相关数据结构


OpSchedulerItem



```
1 class OpSchedulerItem {
 2
     OpQueueable::Ref qitem;
 3
     int cost;
 4
     unsigned priority;
 5
     utime_t start_time;
6
     uint64_t owner;
     epoch_t map_epoch;
7
8
9
       OpSchedulerItem(
       OpQueueable::Ref &&item,
10
       int cost,
11
       unsigned priority,
12
```

```
13
       utime_t start_time,
14
       uint64_t owner,
       epoch_t e)
15
       : qitem(std::move(item)),
16
         cost(cost),
17
        priority(priority),
18
         start_time(start_time),
19
20
         owner(owner),
         map_epoch(e) {}
21
22 };
```

OSDShard



```
1 struct OSDShard {
2   /// priority queue
3   ceph::osd::scheduler::OpSchedulerRef scheduler;
4   OSDShard(
5   int id,
6   CephContext *cct,
7   OSD *osd);
8 };
```

```
1 class OpScheduler {
```

```
public:
// Enqueue op for scheduling
virtual void enqueue(OpSchedulerItem &&item) = 0;

...
};

template <typename T>
class ClassedOpQueueScheduler final : public OpScheduler {
    T queue;
    ...
};
```

```
1 template <typename T, typename K>
2 class WeightedPriorityQueue : public OpQueue <T, K> {
3 ...
4 class Queue{};
5 Queue normal;
6 }
```

初始化


```
1 for (uint32_t i = 0; i < num_shards; i++) {</pre>
     OSDShard *one_shard = new OSDShard(
 2
 3
       i,
       cct,
 4
 5
       this);
     shards.push_back(one_shard);
7 }
8 ========
9 OSDShard::OSDShard(
10
    int id,
11 CephContext *cct,
12
     OSD *osd)
    : shard_id(id),
13
     cct(cct),
14
       osd(osd),
15
       shard_name(string("OSDShard.") + stringify(id)),
16
       sdata_wait_lock_name(shard_name + "::sdata_wait_lock"),
17
       sdata_wait_lock{make_mutex(sdata_wait_lock_name)},
18
       osdmap_lock{make_mutex(shard_name + "::osdmap_lock")},
19
       shard_lock_name(shard_name + "::shard_lock"),
20
       shard_lock{make_mutex(shard_lock_name)},
21
22
       scheduler(ceph::osd::scheduler::make_scheduler(
```

```
23
         cct, osd->whoami, osd->num_shards, id, osd->store->is_rotational(),
24
         osd->store->get_type(), osd->monc)),
       context_queue(sdata_wait_lock, sdata_cond){}
25
26 =======
   OpSchedulerRef make_scheduler() {
27
28
       return std::make_unique<
         ClassedOpQueueScheduler<WeightedPriorityQueue<OpSchedulerItem, client>>>(
29
30
           cct->_conf->osd_op_pq_max_tokens_per_priority,
31
           cct->_conf->osd_op_pq_min_cost
32
33
       );
34 }
```

添加

```
1 =======調用=======
2 OSDShard* sdata = osd->shards[shard_index];
3 sdata->scheduler->enqueue(std::move(item));
4 ======ClassedOpQueueScheduler=====
   void enqueue(OpSchedulerItem &&item) final {
5
      unsigned priority = item.get_priority();
6
7
      unsigned cost = item.get_cost();
8
       queue.enqueue(item.get_owner(), priority, cost, std::move(item));
     }
9
10 ======WeightedPriorityQueue======
11 void enqueue(K cl, unsigned p, unsigned cost, T&& item) final {
     normal.insert(p, cl, cost, std::move(item));
12
13 }
14 // normal是其内部类Queue的实例,就分析到这了,相应的,取出的操作:
15 T dequeue() override {
16
     return normal.pop();
17 }
```

ShardedOpWQ



ShardedThreadPool

在Ceph中,ShardedThreadPool是一个特殊类型的线程池。普通的线程池中,如果任务之间有互斥性,那么正在处理该任务的两个线程有一个必须等待另一个处理完成后才能处理,从而导致线程的阻塞,性能下降。为了解决这个问题,ShardedThreadPool引入了"Shard"的概念。每个线程对应一个任务队列,所有需要顺序执行的任务都放在同一个线程的任务队列里,全部由该线程执行。这样,就可以避免因任务之间的互斥性导致的线程阻塞,从而提高性能。

ShardedOpWQ

```
class ShardedOpWQ : public ShardedThreadPool::ShardedWQ<OpSchedulerItem>
 1
 2
       OSD *osd;
 3
 4
       bool m_fast_shutdown = false;
 5
     public:
       ShardedOpWQ(OSD *o,
 6
 7
           ceph::timespan ti,
 8
           ceph::timespan si,
           ShardedThreadPool* tp)
 9
         : ShardedThreadPool::ShardedWQ<OpSchedulerItem>(ti, si, tp),
10
           osd(o) {}
11
     void _process(uint32_t thread_index, ceph::heartbeat_handle_d *hb) override;
12
     void _enqueue(OpSchedulerItem&& item) override;
13
     void _enqueue_front(OpSchedulerItem&& item) override;
14
     } op_shardedwq;
15
```

入队

```
1 op_shardedwq.queue(
 2
     OpSchedulerItem(
 3
       unique_ptr(new PGOpItem(pg, std::move(op))),
 4
       cost, priority, stamp, owner, epoch));
 5 ========
 6 void OSD::ShardedOpWQ::_enqueue(OpSchedulerItem&& item) {
7
     uint32_t shard_index =
 8
       item.get_ordering_token().hash_to_shard(osd->shards.size());
 9
     OSDShard* sdata = osd->shards[shard_index];
10
11
     bool empty = true;
12
13
       std::lock_guard l{sdata->shard_lock};
14
15
       empty = sdata->scheduler->empty();
       sdata->scheduler->enqueue(std::move(item));
16
     }
17
18
19
       std::lock_guard l{sdata->sdata_wait_lock};
20
       if (empty) {
21
         sdata->sdata_cond.notify_all();
22
23
       } else if (sdata->waiting_threads) {
         sdata->sdata_cond.notify_one();
24
25
       }
26
     }
27 }
```


4读写流程


4.1 从分发请求到完成io

首先要清楚的一些事情:

通信方式采用异步,存储模式使用主备复制,存储方式使用BlueStore







4.2 写操作同步

4.1写操作的最后,issue_op使用send_message_osd_cluster发送了同步消息,这节来观察这个操作的两端是怎么工作的

这函数有四个形式的重载,最终调用的都是Connection::send_message,而send_message实际又由 AsyncConnection实现

```
void OSDService::send_message_osd_cluster(int peer, Message *m, epoch_t
from_epoch)

{
   OSDMapRef next_map = get_nextmap_reserved();
   // service map is always newer/newest
   ceph_assert(from_epoch <= next_map->get_epoch());
```

```
6
 7
     if (next_map->is_down(peer) ||
         next_map->get_info(peer).up_from > from_epoch) {
 8
 9
       m->put();
       release map(next map);
10
       return;
11
12
     }
13
     ConnectionRef peer_con;
14
     if (peer == whoami) {
       peer_con = osd->cluster_messenger->get_loopback_connection();
15
16
     } else {
       peer_con = osd->cluster_messenger->connect_to_osd(
17
       next_map->get_cluster_addrs(peer), false, true);
18
     }
19
     maybe_share_map(peer_con.get(), next_map);
20
21
     peer_con->send_message(m);
     release_map(next_map);
22
23 }
24
25 void OSDService::send_message_osd_cluster(std::vector<std::pair<int,
   Message*>>& messages, epoch_t from_epoch)
26 {
     OSDMapRef next_map = get_nextmap_reserved();
27
28
     ceph_assert(from_epoch <= next_map->get_epoch());
29
     for (auto& iter : messages) {
30
       if (next_map->is_down(iter.first) ||
31
       next_map->get_info(iter.first).up_from > from_epoch) {
32
         iter.second->put();
33
         continue;
34
35
       ConnectionRef peer_con;
36
       if (iter.first == whoami) {
37
         peer_con = osd->cluster_messenger->get_loopback_connection();
38
39
       } else {
40
         peer_con = osd->cluster_messenger->connect_to_osd(
         next_map->get_cluster_addrs(iter.first), false, true);
41
42
       }
       maybe_share_map(peer_con.get(), next_map);
43
       peer_con->send_message(iter.second);
44
45
     }
     release_map(next_map);
46
47 }
48
49 void send_message_osd_cluster(MessageRef m, Connection *con) {
50
     con->send_message2(std::move(m));
51
```

```
52  virtual int send_message2(MessageRef m)
53  {
54   return send_message(m.detach());
55  }
56  */
57 }
58 void send_message_osd_cluster(Message *m, const ConnectionRef& con) {
59   con->send_message(m);
60 }
```

send_messgae之后的流程见<5.7 发送消息>

4.3 接收消息

4.1的流程开始是ms_fast_dispatch,这是谁调用的?

在<5.5 add_fast_dispatch_tail>中,讲了add_dispatcher_tail的流程。类似的还有 add dispatcher head


```
int OSD::init() {
 1
 2
       cluster_messenger->add_dispatcher_head(this);
 3
     void add_dispatcher_head(Dispatcher *d) {
 4
       bool first = dispatchers.empty();
 5
       dispatchers.push_front(d);
 6
       if (d->ms_can_fast_dispatch_any())
         fast_dispatchers.push_front(d);
 8
       if (first)
9
         ready();
10
11
     }
```

这里OSD将自身绑定到了一个fast_dispatchers中,然后cluster_messager就能调用osd的ms_fast_dispatch

具体过程在<5.5 add_fast_dispatch_tail>中说明了。

5通信模块

5.1 OSD 通信类图



OSD注册的Messenger实例列表

编号	Messenger实例名称	作用
1	*ms_public	用来处理OSD和Client之间的消息
2	*ms_cluster	用来处理OSD和集群之间的消息
3	*ms_hbclient	用来处理OSD和其它OSD保持心跳的消息
4	*ms_hb_back_server	用来处理OSD接收心跳消息
5	*ms_hb_front_server	用来处理OSD发送心跳消息
6	*ms_objecter	用来处理OSD和Objecter之间的消息

5.2 主流程

最简单的服务器是这样的模式:


- 1. **创建监听套接字**: 使用 socket 函数创建一个套接字。
- 2. **绑定本机IP和端口**: 使用 bind 函数将套接字绑定到特定的IP地址和端口上。
- 3. **监听**: 使用 listen 函数开始监听这个套接字。
- 4. **创建epoll实例**:使用 epoll_create 函数创建一个epoll实例。
- 5. 注册文件描述符:使用 epol1_ctl 函数将监听套接字注册到epoll实例中,监听 EPOLLIN 事件 (新的连接请求)。
- 6. 等待事件: 使用 epoll wait 函数等待注册在epoll实例上的文件描述符上的事件发生。
- 7. **处理事件**: 当 epoll_wait 返回时,遍历所有就绪的事件,对于每一个事件:
 - 如果是监听套接字上的事件,那么使用「accept 函数接受新的连接,然后使用 epol1_ct1 将新的连接套接字注册到epoll实例中,监听 EPOLLIN 和 EPOLLOUT 事件。
 - 。 如果是连接套接字上的 EPOLLIN 事件,那么读取数据,处理请求。
 - o 如果是连接套接字上的 EPOLLOUT 事件, 那么写入数据, 发送响应。
- 8. **关闭连接**: 当连接结束后,使用 close 函数关闭连接套接字,并使用 epol1_ct1 将其从epoll实例中删除。

ceph的通信模块采用事件驱动的模式,先创建事件中心,事件中心接收自定义的各类事件,触发事件响应时调用相应的回调函数,松散耦合。

ceph_osd.cc 创建Messenger对象 Messenger *ms_public = Messenger::create(g_ceph_context, public_msg_type, entity_name_t::OSD(whoami), "client", nonce); 服务端bind AsyncMessenger::start() 置标志位started=true if (ms_public->bindv(public_bind_addrs, public_addrs) < 0) {</pre> derr << "Failed to bind to " << public_bind_addrs << dendl;</pre> forker.exit(1); 服务端listen int OSD::init(){ // ms_public传入OSD后更名为client_messenger client_messenger->add_dispatcher_tail(this); // 除了客户端外,本文还涉及到和其它osd的通信 cluster_messenger->add_dispatcher_head(this);

5.3 create 流程


创建消息模块、初始化、启动事件监听,但是此时还没有事件加入。




5.4 bindv 流程

绑定本机ip

```
int Messenger::bindv(const entity_addrvec_t& bind_addrs,
          std::optional<entity_addrvec_t> public_addrs)
 return bind(bind_addrs.legacy_addr(), std::move(public_addrs));
    // AsyncMessenger::bind直接调用了bindv
    int AsyncMessenger::bindv(const entity_addrvec_t &bind_addrs,
                std::optional<entity_addrvec_t> public_addrs)
                                                                     class Processor {
                                                                     AsyncMessenger *msgr;
                                                                     ceph::NetHandler net;
     std::set<int> avoid_ports;
                                                                     Worker *worker;
     entity_addrvec_t bound_addrs;
                                                                     std::vector<ServerSocket> listen_sockets;
     unsigned i = 0;
                                                                     EventCallbackRef listen_handler;
     // processors 包含了监听事件: create流程中的work
     for (auto &&p : processors) {
     int r = p->bind(bind addrs, avoid ports, &bound addrs):
     _finish_bind(bind_addrs, bound_addrs);
     return 0:
                            processors::bind
  int Processor::bind(const entity_addrvec_t &bind_addrs,
                                                                                                 // submit_to 去判断目前所在的线程是否是自己的线程,如果是就执行worker-
                                                                                                >listen,反之,则去唤醒自己的线程去执行
    const std::set<int>& avoid ports.
    entity_addrvec_t* bound_addrs)
                                                                                                template <typename func>
                                                                                                void submit_to(int i, func &&f, bool always_async = false) {
  // bind to socket(s)
                                                                                                 ceph_assert(i < MAX_EVENTCENTER && global_centers);</pre>
   SocketOptions opts;
                                                                                                 EventCenter *c = global_centers->centers[i];
   opts.nodelay = msgr->cct->_conf->ms_tcp_nodelay;
                                                                                                 ceph_assert(c);
   opts.rcbuf_size = msgr->cct->_conf->ms_tcp_rcvbuf;
                                                                                                 if (always_async) {
                                                                                                  C_submit_event<func> *event = new C_submit_event<func>(std::move(f),
                                                                              submit_to _
  for (int i = 0; i < conf->ms_bind_retry_count; i++) {
                                                                                                  c->dispatch_event_external(event);
    if (listen_addr.get_port()) {
                                                                                                 } else if (c->in_thread()) {
     worker->center.submit_to(
                                                                                                  f();
     worker->center.get_id(), [this, k, &listen_addr, &opts, &r]() {
                                                                                                  return;
       r = worker->listen(listen_addr, k, opts, &listen_sockets[k]);
                                                                                                 } else {
                                                                                                  C_submit_event<func> event(std::move(f), false);
  // 这个lambda表达式:创建一个匿名函数,参数有k, listen_addr,opts,r,
                                                                                                  c->dispatch_event_external(&event);
  函数体是r=worker listen...
                                                                                                  event.wait():
                              work->listen
int PosixWorker::listen(entity_addr_t &sa, unsigned addr_slot,
const SocketOptions &opt,
          ServerSocket *sock)
int listen_sd = net.create_socket(sa.get_family(), true);
int r = net.set_nonblock(listen_sd);
 r = net.set_socket_options(listen_sd, opt.nodelay, opt.rcbuf_size);
// 给listen_sd绑定地址
r = ::bind(listen_sd, sa.get_sockaddr(), sa.get_sockaddr_len());
// 监听listen_sd
r = ::listen(listen_sd, cct->_conf->ms_tcp_listen_backlog);
 *sock = ServerSocket(
   std::unique_ptr<PosixServerSocketImpl>(
 new PosixServerSocketImpl(net, listen_sd, sa, addr_slot)));
return 0;
```



5.6 接受新的连接



5.7 发送消息

```
上层调用
        int AsyncConnection::send_message(Message *m)
        if (!m->get_priority())
         m->set_priority(async_msgr->get_default_send_priority());
        m->get_header().src = async_msgr->get_myname();
        m->set_connection(this);
        protocol->send_message(m);
        return 0;
1. AsyncConnection::send_message对消息做一层封装,然后使用protocol->send_message(m);
2. protocol有两种实现: ProtocolV1 和 ProtocolV2,选择哪一个实现取决于建立连接时,对端支持的协议类型
3. 如果对端满足protocol->proto_type == 2;那么使用V2,否则使用V1,如果是回环地址,也使用V1。
4. 最终都是通过connection->center->dispatch_event_external(connection->write_handler);将消息递给事
 件中心,由事件中心去调度。
                                       回调
```

回调函数是protocol->write_event();

此函数检查网络连接无误后调用 r = connection->_try_send();

到此,就发送完成了

参考

【ceph】AsyncMessenger 网络模块总结--编辑中 - bdy - 博客园

【ceph】CEPH源码解析:读写流程_ceph源码分析-CSDN博客

ceph的数据存储之路(5) -----osd数据处理 - 一只小江的个人空间 - OSCHINA - 中文开源技术交流社区