

数据修复

ceph版本: <https://github.com/ceph/ceph/tree/v18.2.1>

PG日志记录了PG内对象的所有操作，包括创建、修改和删除等。每个日志条目（log entry）包含了执行操作时的元数据，例如对象的版本号（eversion）、操作类型、对象的元数据（如大小、时间戳等），这些日志条目按照操作发生的顺序排列，形成了一个操作历史记录。

当Ceph执行数据恢复或同步操作时，它会参考PG日志来确定对象的当前状态。例如，在Recovery阶段，Ceph会使用PG日志来恢复缺失的对象副本，确保所有副本都是最新的。在这个过程中，PG日志充当了元数据变更的记录器，帮助Ceph维护数据的一致性和完整性。

Recovery是依据PG日志中的缺失记录来修复不一致的对象。Backfill是PG通过重新扫描所有的对象，对比发现缺失的对象，通过整体拷贝来修复。当一个OSD失效时间过长导致无法根据PG日志来修复，或者新加入的OSD导致数据迁移时，就会启动Backfill过程。

资源预约

如果有大量pg同时进行修复，那可能会影响到客户端读写的性能，需要对pg同时修复的数量进行限制，于是修复前需要进行资源的预约。

```
1 void request_reservation(  
2     T item,                ///< [in] reservation key  
3     Context *on_reserved,  ///< [in] callback to be called on reservation  
4     unsigned prio,         ///< [in] priority  
5     Context *on_preempt = 0 ///< [in] callback to be called if we are  
    preempted (optional)  
6 ) {  
7     std::lock_guard l(lock);  
8     // 资源关键字、优先级、预留成功时的回调、可选的抢占回调  
9     Reservation r(item, prio, on_reserved, on_preempt);  
10  
11     // 资源优先队列  
12     queues[prio].push_back(r);  
13     // item -> 资源位置  
14     queue_pointers.insert(std::make_pair(item, std::make_pair(prio, --  
        (queues[prio].end()))));  
15     // 资源分配  
16     do_queues();  
17 }
```

取消预约

```
1 void cancel_reservation(  
2     T item ///  
3 ) {  
4     std::lock_guard l(lock);  
5     auto i = queue_pointers.find(item);  
6     if (i != queue_pointers.end()) {  
7         unsigned prio = i->second.first;  
8         const Reservation &r = *i->second.second;  
9         delete r.grant;  
10        delete r.preempt;  
11        queues[prio].erase(i->second.second);  
12        if (queues[prio].empty()) {  
13            queues.erase(prio);  
14        }  
15        queue_pointers.erase(i);  
16    } else {  
17        auto p = in_progress.find(item);  
18        if (p != in_progress.end()) {  
19            if (p->second.preempt) {  
20                preempt_by_prio.erase(std::make_pair(p->second.prio, p->  
21                    second.item));  
22                delete p->second.preempt;  
23            }  
24            in_progress.erase(p);  
25        }  
26        // 继续给队列中其他的请求分配  
27        do_queues();  
28    }
```

do_queues

做资源分配的函数

```
1 void do_queues() {  
2     // 抢占或回收资源  
3     while (!preempt_by_prio.empty() &&  
4         (in_progress.size() > max_allowed ||  
5         preempt_by_prio.begin()->first < min_priority)) {  
6         preempt_one();  
7     }  
8 }
```

```

9      while (!queues.empty()) {
10         // choose highest priority queue
11         auto it = queues.end();
12         --it;
13         ceph_assert(!it->second.empty());
14         // 如果优先级过低
15         if (it->first < min_priority) {
16             break;
17         }
18
19         // 1. 正在进行的资源分配数量大于阈值
20         // 2. 存在可以抢占的资源
21         // 3. 优先级高于可抢占资源
22         if (in_progress.size() >= max_allowed &&
23             !preempt_by_prio.empty() &&
24             it->first > preempt_by_prio.begin()->first) {
25             preempt_one();
26         }
27         // 正在进行的资源分配数量大于阈值
28         if (in_progress.size() >= max_allowed) {
29             break; // no room
30         }
31         // 给资源
32         Reservation p = it->second.front();
33         // 从分配队列中取出待分配对象
34         queue_pointers.erase(p.item);
35         it->second.pop_front();
36         if (it->second.empty()) {
37             queues.erase(it);
38         }
39         // 分配资源
40         f->queue(p.grant);
41         p.grant = nullptr;
42         in_progress[p.item] = p;
43         if (p.preempt) {
44             s.insert(std::make_pair(p.prio, p.item));
45         }
46     }
47 }

```

数据修复

数据修复有两个过程，一个是Recovery（修复）一个是Backfill（回填），当数据无法通过日志修复时（Recovery），就通过向其它OSD寻找完整的数据，拷贝到自己这（Backfill），一般前者作为临时故障的修复，后者作为长时间故障的修复或用于集群变更时PG的迁移。

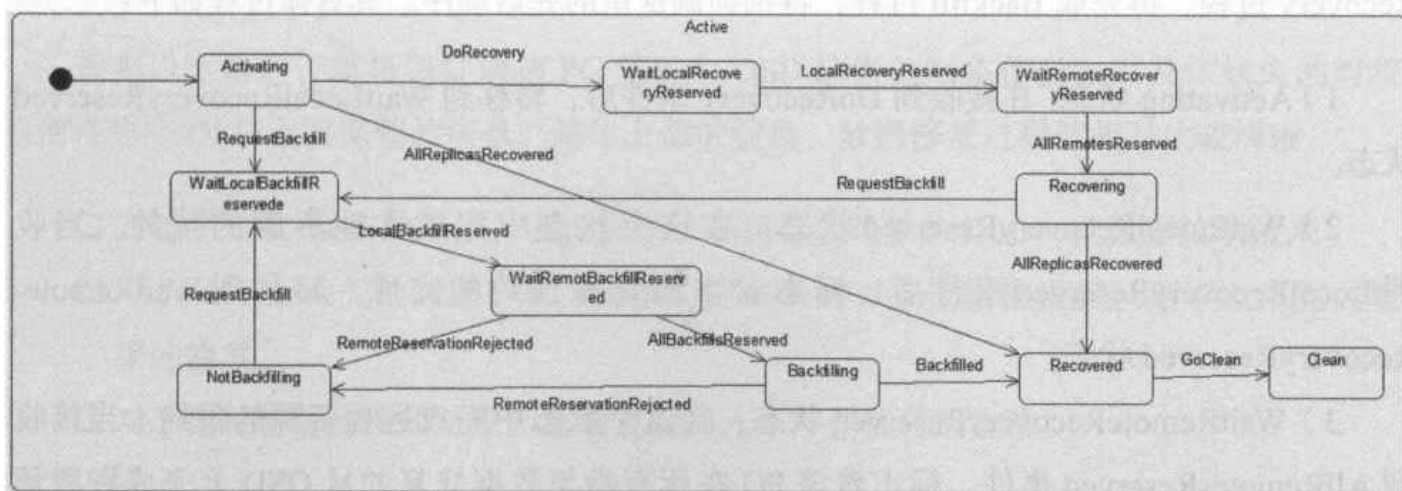


图 11-1 修复过程状态转换图

情况1: Activating状态, 如果副本完整不需要修复, 直接转换到Recovered状态, 再到Clean状态

情况2: Activating状态, 不需要Recovery时, 就进行Backfill过程:

WaitLocalBackfillReserved状态申请资源, 成功后, 进入WaitRemoteBackfillReserved状态, **所有**副本资源预约成功后, 主OSD进入Backfilling状态, 完成修复进入Recovered状态。

异常: 资源预约失败后进入NotBackfill状态, 等待事件重新发起Backfill过程

情况3: Activating状态, 进行Backfill过程:

WaitLocalRecoveryReserved状态申请资源, 成功后转到WaitRemoteRecoveryReserved状态, 当**所有**参与数据修复的OSD都预约到资源后, 转到Recovering状态, 该状态完成之后, 会根据是否需要Backfill决定转入哪一个状态 (见上图)

Recovery过程

数据修复的依据是在 Peering 过程中产生的如下信息：

- ❑ 主副本上的缺失对象的信息保存在 pg_log 类的 pg_missing_t 结构中。
- ❑ 各从副本上的缺失对象信息保存在 OSD 对应的 peer_missing 中的 pg_missing_t 结构中。
- ❑ 缺失对象的位置信息保存在类 MissingLoc 中。

根据以上信息，就可以知道该 PG 里各个 OSD 缺失的对象信息，以及该缺失的对象目前在哪些 OSD 上有完整的信息。基于上面的信息，数据修复过程就相对比较清晰：

- ❑ 对于主 OSD 缺失的对象，随机选择一个拥有该对象的 OSD，把数据拉取过来。
- ❑ 对于 replica 缺失的对象，从主副本上把缺失的对象数据推送到从副本上来完成数据的修复。
- ❑ 对于比较特殊的快照对象，在修复时加入了一些优化的方法。

先修复主 OSD 上缺失或不一致的对象，然后修复从 OSD 上的对象。

当前 Recovery 一共有两种方式

1. **Pull** 主 OSD 自身存在待修复对象，由主 OSD 按照 missing_loc 选择合适的副本去拉取待修复的对象目标版本至本地，完成修复方式。
2. **Push** 主 OSD 知道从 OSD 存在待修复对象，主动推送每个待修复对象目标版本到相应从 OSD，然后由其本地完成修复的方式。

主 OSD 自我修复过程中，可能有多个从 OSD 拥有待修复对象目标版本，处于负载均衡的目的可以随机选择副本，完成修复之后，开始修复各个从 OSD 损坏的对象，依靠 peering 阶段生成的 missing 列表，通过 push 的方式逐个完成从 OSD 的修复。

流程总览

```
1 主OSD:
2 OSD::do_recovery
3 >> pg->start_recovery_ops
4
5 PrimaryLogPG::start_recovery_ops
6 >> 1 recover_primary
7 >> 2 recover_replicas
8 >> 状态转变，见状态图，完成修复或进入backfill流程
9
10 1
11 PrimaryLogPG::recover_primary
12 >> 获取缺失对象的最后一条日志
```

```

13 >> 1.1 处理”版本回退“操作，执行修复 recover_missing
14 >> 1.2 run_recovery_op 修复其它的对象
15
16 1.1
17 PrimaryLogPG::recover_missing
18 >> 修复已经删除的对象
19 >> 修复snap对象前，需要先递归修复head
20 >> 修复其它类型对象 pgbackend->recover_object
21
22 ReplicatedBackend::recover_object
23 >> prepare_pull 准备PullOp
24
25 1.2
26 ReplicatedBackend::run_recovery_op
27 >> send_pulls
28
29 2
30 PrimaryLogPG::recover_replicas
31 >> 遍历所有需要修复的OSD，准备PushOp
32 >> run_recovery_op
33
34 ReplicatedBackend::run_recovery_op
35 >> send_pushes
36
37 从OSD：
38 当主OSD send_pulls，从OSD收到
39 ReplicatedBackend::handle_pull
40 >> 封装对象数据，PushOp推送
41
42 当主OSD send_pushes，从OSD收到
43 ReplicatedBackend::handle_push
44 >> submit_push_data
45 >>>> submit_push_complete
46 >>>>> ObjectStore::Transaction->clone_range // 将要修改的操作提交给事务，具体运行机制未分析

```

启动

```

1 void PGRecovery::run(
2     OSD *osd,
3     OSDShard *sdata,
4     PGRef& pg,
5     ThreadPool::TPHandle &handle)
6 {
7     osd->logger->tinc(

```

```

8     l_osd_recovery_queue_lat,
9     time_queued - ceph_clock_now());
10    osd->do_recovery(pg.get(), epoch_queued, reserved_pushes, priority, handle);
11    pg->unlock();
12 }

```

do_recovery

```

1 void OSD::do_recovery(
2     PG *pg, epoch_t queued, uint64_t reserved_pushes, int priority,
3     ThreadPool::TPHandle &handle) {
4     uint64_t started = 0;
5
6     float recovery_sleep = get_osd_recovery_sleep();
7     {
8         // 休眠一定的时间再开始修复
9         return;
10    }
11    // 开始修复
12    bool do_unfound = pg->start_recovery_ops(reserved_pushes, handle,
13        &started);
14    if (do_unfound) { // 有些对象不知道能在哪个OSD上找到
15        PeeringCtx rctx;
16        rctx.handle = &handle;
17        pg->find_unfound(queued, rctx); // 去找那部分对象
18        dispatch_context(rctx, pg, pg->get_osdmap()); // 给其它OSD发送信息
19    }
20 }

```

start_recovery_ops

```

1 bool PrimaryLogPG::start_recovery_ops(
2     uint64_t max,
3     ThreadPool::TPHandle &handle,
4     uint64_t *ops_started) {
5     uint64_t &started = *ops_started;
6     started = 0;
7     bool work_in_progress = false;
8     bool recovery_started = false;
9     // 1 状态检查
10    ceph_assert(is_primary());

```

```

11     ceph_assert(is_peered());
12     ceph_assert(!recovery_state.is_deleting());
13
14     ceph_assert(recovery_queued);
15     recovery_queued = false;
16
17     if (!state_test(PG_STATE_RECOVERING) &&
18         !state_test(PG_STATE_BACKFILLING)) {
19         return have_unfound();
20     }
21
22 // 2 获取missing，missing是缺失的对象
23     const auto &missing = recovery_state.get_pg_log().get_missing();
24
25 // 2.1 unfound 是缺失但没有找到正确副本所在位置的对象
26     uint64_t num_unfound = get_num_unfound();
27
28 // 2.2 如果不缺失对象，设置 info.last_complete = info.last_update;
29     if (!recovery_state.have_missing()) {
30         recovery_state.local_recovery_complete();
31     }
32
33 // 3 主OSD没有missing，或者所有的missing都是unfound对象，就先修复副本
34     if (!missing.have_missing() ||
35         recovery_state.all_missing_unfound()) {
36         // 修复副本
37         started = recover_replicas(max, handle, &recovery_started);
38     }
39
40 // 3.1 表示启动修复的对象数量为0，修复主OSD上的对象
41     if (!started) {
42         started += recover_primary(max, handle);
43     }
44
45 // 3.2 如果仍然为0，且num_unfound发生变化，那么再次启动修复
46     if (!started && num_unfound != get_num_unfound()) {
47         // 修复副本
48         started = recover_replicas(max, handle, &recovery_started);
49     }
50
51     if (started || recovery_started)
52         work_in_progress = true;
53
54     bool deferred_backfill = false; // 推迟backfill
55
56 // 4 决定推迟backfill还是立即开始
57     if (recovering.empty() &&

```



```

58     state_test(PG_STATE_BACKFILLING) &&
59     !get_backfill_targets().empty() && started < max &&
60     missing.num_missing() == 0 &&
61     waiting_on_backfill.empty()) {
62     if (get_osdmap()->test_flag(CEPH_OSDMAP_NOBACKFILL)) {
63         deferred_backfill = true;
64     } else if (get_osdmap()->test_flag(CEPH_OSDMAP_NOREBALANCE) &&
!is_degraded()) {
65         deferred_backfill = true;
66     } else if (!recovery_state.is_backfill_reserved()) {
67         // 如果backfill_reserved没有设置
68         /* DNNOTE I think this branch is dead */
69         if (!backfill_reserving) {
70             backfill_reserving = true;
71             queue_peering_event(
72                 PGPeeringEventRef(
73                     std::make_shared<PGPeeringEvent>(
74                         get_osdmap_epoch(),
75                         get_osdmap_epoch(),
76                         PeeringState::RequestBackfill())));
77         }
78         deferred_backfill = true;
79     } else {
80         // 开始backfill过程
81         started += recover_backfill(max - started, handle,
&work_in_progress);
82     }
83 }
84
85 // 5 if: 是否有正在进行的数据恢复操作, 是否有正在进行的工作, 是否有活跃的恢复操作,
86 // 是否有延迟的数据回填操作
87 // 返回值为true: 表示需要进行数据修复, 此时没有正在运行的恢复工作, 且有未找到的对象
88 if (!recovering.empty() ||
89     work_in_progress || recovery_ops_active > 0 || deferred_backfill)
90     return !work_in_progress && have_unfound();
91
92 ceph_assert(recovering.empty());
93 ceph_assert(recovery_ops_active == 0);
94
95 int unfound = get_num_unfound();
96 if (unfound) {
97     return true;
98 }
99
100 if (missing.num_missing() > 0) {
101     // 这不应该发生

```

```

102         osd->clog->error() << info.pgid << " Unexpected Error: recovery ending
    with "
103             << missing.num_missing() << ": " << missing.get_items();
104         return false;
105     }
106
107     if (needs_recovery()) {
108         // 这不应该发生
109         osd->clog->error() << info.pgid
110             << " Unexpected Error: recovery ending with missing
    replicas";
111         return false;
112     }
113
114     // 6 状态转换
115     if (state_test(PG_STATE_RECOVERING)) {
116         state_clear(PG_STATE_RECOVERING);
117         state_clear(PG_STATE_FORCED_RECOVERY);
118         if (needs_backfill()) {
119             queue_peering_event(
120                 PGPeeringEventRef(
121                     std::make_shared<PGPeeringEvent>(
122                         get_osdmap_epoch(),
123                         get_osdmap_epoch(),
124                         PeeringState::RequestBackfill())));
125         } else {
126             state_clear(PG_STATE_FORCED_BACKFILL);
127             queue_peering_event(
128                 PGPeeringEventRef(
129                     std::make_shared<PGPeeringEvent>(
130                         get_osdmap_epoch(),
131                         get_osdmap_epoch(),
132                         PeeringState::AllReplicasRecovered())));
133         }
134     } else { // backfilling
135         state_clear(PG_STATE_BACKFILLING);
136         state_clear(PG_STATE_FORCED_BACKFILL);
137         state_clear(PG_STATE_FORCED_RECOVERY);
138         queue_peering_event(
139             PGPeeringEventRef(
140                 std::make_shared<PGPeeringEvent>(
141                     get_osdmap_epoch(),
142                     get_osdmap_epoch(),
143                     PeeringState::Backfilled())));
144     }
145
146     return false;

```

```
147 }
148
```

recover_primary

```
1 uint64_t PrimaryLogPG::recover_primary(uint64_t max, ThreadPool::TPHandle
  &handle) {
2     ceph_assert(is_primary());
3
4     const auto &missing = recovery_state.get_pg_log().get_missing();
5
6     // look at log!
7     pg_log_entry_t *latest = 0;
8     unsigned started = 0;
9     int skipped = 0;
10
11 // 1 获取一个Handle, 用于Push和Pull
12     PGBackend::RecoveryHandle *h = pgbackend->open_recovery_op();
13     map<version_t, hobject_t>::const_iterator p =
        missing.get_rmissing().lower_bound(recovery_state.get_pg_log().get_log().last_r
        equested);
14     while (p != missing.get_rmissing().end()) { // 遍历未被修复的对象
15         handle.reset_tp_timeout();
16         hobject_t soid;
17         version_t v = p->first;
18
19 // 2 latest 是日志记录中保存的该缺失对象的最后的一条日志, soid为缺失的对象
20         auto it_objects = recovery_state.get_pg_log().get_log().objects.find(p-
        >second);
21         if (it_objects != recovery_state.get_pg_log().get_log().objects.end())
22         {
23             latest = it_objects->second;
24             ceph_assert(latest->is_update() || latest->is_delete());
25             soid = latest->soid;
26         } else {
27             latest = 0;
28             soid = p->second;
29         }
30         const pg_missing_item &item = missing.get_items().find(p->second)-
        >second;
31         ++p;
32
33         hobject_t head = soid.get_head();
34         eversion_t need = item.need;
```

```

35 // 3 开始修复
36     if (latest) {
37         switch (latest->op) {
38             case pg_log_entry_t::CLONE:
39                 /*
40                  暂时取消了对这种特殊情况的处理，直到我们能够从旧的SnapSet中正确地构建一个准
41                  确的SnapSet。
42                  */
43                 break;
44 // 4 该记录类型为LOST_REVERT：该revert操作为数据不一致时，管理员通过命令强行回退到指定版本
45             case pg_log_entry_t::LOST_REVERT: {
46
47 // 4.1 此条件表示：日志记录显示当前已经拥有回退的版本，
48                 if (item.have == latest->reverting_to) {
49                     // 获取该对象的ObjectContext
50                     ObjectContextRef obc = get_object_context(soid, true);
51
52 // 4.1.1 如果检查对象当前的版本 obc->obs.oi.version 等于 latest->version，说明回退操作已完成
53                     if (obc->obs.oi.version == latest->version) {
54                         // I'm already reverting
55                     } else {
56 // 4.1.2 说明没有执行回退操作，直接修改对象的版本号为latest->version，关于为什么如此，
57 // 见下文
58                         obc->obs.oi.version = latest->version;
59
60                         ObjectStore::Transaction t;
61                         bufferlist b2;
62                         obc->obs.oi.encode(
63                             b2,
64                             get_osdmap()->get_features(CEPH_ENTITY_TYPE_OSD,
65                             nullptr));
66                         ceph_assert(!pool.info.require_rollback());
67                         t.setattr(coll, ghobject_t(soid), OI_ATTR, b2);
68                         // 更新恢复状态
69                         recovery_state.recover_got(
70                             soid,
71                             latest->version,
72                             false,
73                             t);
74
75                         ++active_pushes;
76
77                         t.register_on_applied(new
78                             C_OSD_AppliedRecoveredObject(this, obc));

```

```

76         t.register_on_commit(new C_OSD_CommittedPushedObject(
77             this,
78             get_osdmap_epoch(),
79             info.last_complete));
80         osd->store->queue_transaction(ch, std::move(t));
81         continue;
82     }
83     } else {
84 // 4.2 需要拉取该reverting_to版本的对象，这里不做特殊处理，只是检查所有OSD是否拥有该版本
      的对象，如果有就加入到missing_loc记录该版本的位置信息，由后续修复继续来完成
85         eversion_t alternate_need = latest->reverting_to;
86
87         set<pg_shard_t> good_peers;
88         for (auto p = recovery_state.get_peer_missing().begin();
89             p != recovery_state.get_peer_missing().end();
90             ++p) {
91             if (p->second.is_missing(soid, need) &&
92                 p->second.get_items().at(soid).have ==
93                 alternate_need) {
94                 good_peers.insert(p->first);
95             }
96         }
97         recovery_state.set_revert_with_targets(soid, good_peers);
98         /*
99         void PeeringState::set_revert_with_targets(
100             const hobject_t &soid,
101             const set<pg_shard_t> &good_peers) {
102             for (auto &&peer: good_peers) {
103                 missing_loc.add_location(soid, peer);
104             }
105         }
106         */
107     } break;
108 }
109 }
110
111 // 5 如果当前soid没有在修复
112     if (!recovering.count(soid)) {
113         if (recovering.count(head)) { // 或者head在修复
114             ++skipped;
115         } else {
116             // 修复
117             int r = recover_missing(soid, need,
118                 recovery_state.get_recovery_op_priority(), h);
119             switch (r) {
120                 case PULL_YES:

```

```

120             ++started;
121             break;
122             case PULL_HEAD:
123                 ++started;
124             case PULL_NONE:
125                 ++skipped;
126                 break;
127             default:
128                 ceph_abort();
129             }
130             if (started >= max)
131                 break;
132         }
133     }
134
135     if (!skipped)
136         recovery_state.set_last_requested(v);
137 }
138
139 // 6 把PullOp或PushOp封装的消息发送出去
140 pgbackend->run_recovery_op(h, recovery_state.get_recovery_op_priority());
141 return started;
142 }
143

```

书上的例子：

例 11-1 日志修复过程。

PG 日志的记录如下：每个单元代表一条日志记录，分别为对象的名字和版本以及操作，版本的格式为（epoch,version）。灰色的部分代表本 OSD 上缺失的日志记录，该日志记录是从权威日志记录中拷贝过来的，所以当前该日志记录是连续完整的。

obj2(1,3) modify	obj1(1,4) modify	obj2(1,5) modify	obj1(1,6) modify	obj1(1,7) modify	obj1(1,8) modify
------------------	------------------	------------------	------------------	------------------	------------------

情况 1：正常情况的修复。

缺失的对象列表为 [obj1, obj2]。当前修复对象为 obj1。由日志记录可知：对象 obj1 被修改过三次，分别为版本 6,7,8。当前拥有的 obj1 对象的版本 have 值为 4，修复时只修复到最后修改的版本 8 即可。

情况 2：最后一个操作为 LOST_REVERT 类型的操作。

obj2(1,3) modify	obj1(1,4) modify	obj2(1,5) modify	obj1(1,6) modify	obj1(1,7) modify	obj1(1,8) lost_revert_ version = 8 prior_version=7 reverting_to=4
------------------	------------------	------------------	------------------	------------------	---

对于要修复的对象 obj1，最后一次操作为 LOST_REVERT 类型的操作，该操作当前版本 version 为 8，修改前的版本 prior_version 为 7，回退版本 reverting_to 为 4。

在这种情况下，日志显示当前已经有版本 4，检查对象 obj1 的实际版本，也就是 object_info 里保存的版本号：

1) 如果该值是 8，说明最后一次 revert 操作成功，不需要做任何修复动作。

2) 如果该值是 4，说明 LOST_REVERT 操作就没有执行。当然数据内容已经是版本 4 了，只需要修改 object_info 的版本为 8 即可。

如果回退的版本 reverting_to 不是版本 4，而是版本 6，那么最终还是需要把 obj1 的数据修复到版本 6 的数据。Ceph 在这里的处理，仅仅是检查其他 OSD 缺失的对象中是否有版本 6，如果有，就加入到 missing_loc 中，记录拥有该版本的 OSD 位置，待后续继续修复。

最后一种情况，如果是版本 6，对象中并没有版本 6 的数据，将数据修复为版本 6，当前版本设置为 8。

recover_missing

```
1 int PrimaryLogPG::recover_missing(  
2     const hobject_t &soid, eversion_t v,  
3     int priority,  
4     PGBackend::RecoveryHandle *h) {  
5  
6 // 1 如果是unfound对象，无法修复  
7     if (recovery_state.get_missing_loc().is_unfound(soid)) {
```

```

8         return PULL_NONE;
9     }
10
11 // 2 已删除的对象
12     if (recovery_state.get_missing_loc().is_deleted(soid)) {
13 // 2.1 开始修复操作
14         start_recovery_op(soid);
15         // 确保不在修复中
16         ceph_assert(!recovering.count(soid));
17         // 加入修复队列
18         recovering.insert(make_pair(soid, ObjectContextRef()));
19         epoch_t cur_epoch = get_osdmap_epoch();
20         remove_missing_object(soid, v, new LambdaContext([=, this](int) {
21             std::scoped_lock locker{*this};
22             if (!pg_has_reset_since(cur_epoch)) {
23                 bool object_missing = false;
24                 for (const auto &shard : get_acting_recovery_backfill()) {
25                     if (shard == pg_whoami)
26                         continue;
27                     if (recovery_state.get_peer_missing(shard).is_missing(soid))
28                         {
29                         object_missing = true;
30                         break;
31                     }
32                 }
33                 if (!object_missing) {
34                     object_stat_sum_t stat_diff;
35                     stat_diff.num_objects_recovered = 1;
36                     if (scrub_after_recovery)
37                         stat_diff.num_objects_repaired = 1;
38                     on_global_recover(soid, stat_diff, true);
39                 } else {
40                     auto recovery_handle = pgbackend->open_recovery_op();
41                     pgbackend->recover_delete_object(soid, v, recovery_handle);
42                     pgbackend->run_recovery_op(recovery_handle, priority);
43                 }
44             }
45         }));
46         return PULL_YES;
47     }
48 // is this a snapped object? if so, consult the snapset.. we may not need the
49 // 3 快照对象
50     ObjectContextRef obc;
51     ObjectContextRef head_obc;
52     if (soid.snap && soid.snap < CEPH_NOSNAP) {

```



```

53         // do we have the head?
54         hobject_t head = soid.get_head();
55         if (recovery_state.get_pg_log().get_missing().is_missing(head)) {
56             if (recovering.count(head)) {
57                 return PULL_NONE;
58             } else {
59                 int r = recover_missing(
60                     head,
61                     recovery_state.get_pg_log().get_missing().get_items().find(head)->second.need,
62                     priority,
63                     h);
64                 if (r != PULL_NONE)
65                     return PULL_HEAD;
66                 return PULL_NONE;
67             }
68         }
69         head_obc = get_object_context(
70             head,
71             false,
72             0);
73         ceph_assert(head_obc);
74     }
75     start_recovery_op(soid);
76     ceph_assert(!recovering.count(soid));
77     recovering.insert(make_pair(soid, obc));
78
79 // 4 修复对象
80     int r = pgbackend->recover_object(soid, v, head_obc, obc, h);
81     ceph_assert(r >= 0);
82     return PULL_YES;
83 }

```

recover_object

pgbackend封装了不同类型的Pool的实现。ReplicatedBackend实现了replicate类型的PG相关的底层功能，ECbackend实现了Erasure code类型的PG相关的底层功能。

我们讨论基于副本的修复。

```

1  int ReplicatedBackend::recover_object(
2      const hobject_t &hoid,
3      eversion_t v,
4      ObjectContextRef head,
5      ObjectContextRef obc,
6      RecoveryHandle *_h) {

```

```

7   RPGHandle *h = static_cast<RPGHandle *>(_h);
8   if (get_parent()->get_local_missing().is_missing(hoid)) {
9       ceph_assert(!obc);
10      // 把请求封装为PullOp
11      prepare_pull(v, hoid, head, h);
12  } else {
13      ceph_assert(obc);
14      // 把请求封装为PushOp
15      int started = start_pushes(hoid, obc, h);
16      if (started < 0) {
17          pushing[hoid].clear();
18          return started;
19      }
20  }
21  return 0;
22 }

```

1 pull

```

1 struct PullOp {
2     hobject_t soid;                                // 需要拉取的对象
3     ObjectRecoveryInfo recovery_info;              // 对象修复的信息
4     ObjectRecoveryProgress recovery_progress;      // 对象修复进度信息
5 };
6
7 struct ObjectRecoveryInfo {
8     hobject_t soid;
9     eversion_t version;
10    uint64_t size;
11    object_info_t oi;
12    SnapSet ss;                                     // 修复对象的快照信息
13
14    interval_set<uint64_t> copy_subset;             // 修复快照时，需要从其它OSD拷贝到本地的对
象的区段集合
15    std::map<hobject_t, interval_set<uint64_t>> clone_subset;
16    // clone对象修复时，需要从本地拷贝来修复的区间
17    bool object_exist;
18 }
19
20 struct ObjectRecoveryProgress {
21     uint64_t data_recovered_to;                    // data已修复的位置指针
22     std::string omap_recovered_to;                 // omap已修复的位置指针
23     bool first;                                    // 是否是首次修复
24     bool data_complete;                            // data是否修复完成
25     bool omap_complete;                            // omap是否修复完成

```

```
26     bool error = false;
27 }
```

```
1 void ReplicatedBackend::prepare_pull(
2     eversion_t v,           // 要拉取对象的版本信息
3     const hobject_t& soid,   // 要拉取的对象
4     ObjectContextRef headctx, // 拉取对象的ObjectContext信息
5     RPGHandle *h){          // 封装后保存的RecoveryHandle
6 // 1 获取PG对象
7     const auto missing_iter = get_parent()-
8 >get_local_missing().get_items().find(soid);
9     ceph_assert(missing_iter != get_parent()-
10 >get_local_missing().get_items().end());
11     eversion_t _v = missing_iter->second.need;
12     ceph_assert(_v == v);
13
14 // 2 missing_loc 包含缺失对象的位置, peering_missing包含其它节点缺失对象的信息
15     const map<hobject_t, set<pg_shard_t>> &missing_loc(
16         get_parent()->get_missing_loc_shards());
17     const map<pg_shard_t, pg_missing_t> &peer_missing(
18         get_parent()->get_shard_missing());
19
20 // 3 查找soid所在的OSD集合
21     map<hobject_t, set<pg_shard_t>>::const_iterator q = missing_loc.find(soid);
22     ceph_assert(q != missing_loc.end());
23     ceph_assert(!q->second.empty());
24
25 // 4 选择一个特定的分片 (OSD) 作为拉取操作的目标
26     auto p = q->second.end();
27     if (cct->_conf->osd_debug_feed_pullee >= 0) {
28         for (auto it = q->second.begin(); it != q->second.end(); it++) {
29             if (it->osd == cct->_conf->osd_debug_feed_pullee) {
30                 p = it;
31                 break;
32             }
33         }
34     }
35
36 // 4.1 如果没有找到特定的pullee, 可能是用户输入了错误的信息, 随机选择一个目标
37     if (p == q->second.end()) {
38         // probably because user feed a wrong pullee
39         p = q->second.begin();
40         std::advance(p, ceph::util::generate_random_number<int>(0,
41             q->second.size() - 1));
42     }
43     ceph_assert(get_osdmap()->is_up(p->osd));
```

```

41     pg_shard_t fromshard = *p;
42
43 // 5 确保选中的OSD上确实需要的对象
44     ceph_assert(peer_missing.count(fromshard));
45     const pg_missing_t &pmissing = peer_missing.find(fromshard)->second;
46     if (pmissing.is_missing(soid, v)) {
47         ceph_assert(pmissing.get_items().find(soid)->second.have != v);
48         v = pmissing.get_items().find(soid)->second.have;
49         ceph_assert(get_parent()->get_log().get_log().objects.count(soid) &&
50             (get_parent()->get_log().get_log().objects.find(soid)-
51 >second->op ==
52             pg_log_entry_t::LOST_REVERT) &&
53             (get_parent()->get_log().get_log().objects.find(soid)
54             ->second->reverting_to ==v));
55     }
56     ObjectRecoveryInfo recovery_info;
57     ObcLockManager lock_manager;
58 // 6 如果是快照
59     if (soid.is_snap()) {
60         ceph_assert(!get_parent()-
61 >get_local_missing().is_missing(soid.get_head()));
62         ceph_assert(headctx);
63         // check snapset
64         SnapSetContext *ssc = headctx->ssc;
65         ceph_assert(ssc);
66         recovery_info.ss = ssc->snapset;
67         calc_clone_subsets(
68             ssc->snapset, soid, get_parent()->get_local_missing(),
69             get_info().last_backfill,
70             recovery_info.copy_subset,
71             recovery_info.clone_subset,
72             lock_manager);
73         // FIXME: this may overestimate if we are pulling multiple clones in
74         parallel...
75         ceph_assert(ssc->snapset.clone_size.count(soid.snap));
76         recovery_info.size = ssc->snapset.clone_size[soid.snap];
77         recovery_info.object_exist = missing_iter-
78 >second.clean_regions.object_is_exist();
79     } else {
80 // 6.1 如果是head对象，拉取全部
81         // pulling head or unversioned object.
82         // always pull the whole thing.
83         recovery_info.copy_subset.insert(0, (uint64_t)-1);
84         assert(HAVE_FEATURE(parent->min_peer_features(), SERVER_OCTOPUS));

```

```

84         recovery_info.copy_subset.intersection_of(missing_iter-
>second.clean_regions.get_dirty_regions());
85         recovery_info.size = ((uint64_t)-1);
86         recovery_info.object_exist = missing_iter-
>second.clean_regions.object_is_exist();
87     }
88
89     // 7 创建PullOp对象，设置拉取操作的相关信息
90     h->pulls[fromshard].push_back(PullOp());
91     PullOp &op = h->pulls[fromshard].back();
92     op.soid = soid;
93
94     op.recovery_info = recovery_info;
95     op.recovery_info.soid = soid;
96     op.recovery_info.version = v;
97     op.recovery_progress.data_complete = false;
98     op.recovery_progress.omap_complete = !missing_iter-
>second.clean_regions.omap_is_dirty();
99     op.recovery_progress.data_recovered_to = 0;
100     op.recovery_progress.first = true;
101
102     ceph_assert(!pulling.count(soid));
103     pull_from_peer[fromshard].insert(soid);
104     PullInfo &pi = pulling[soid];
105     pi.from = fromshard;
106     pi.soid = soid;
107     pi.head_ctx = headctx;
108     pi.recovery_info = op.recovery_info;
109     pi.recovery_progress = op.recovery_progress;
110     pi.cache_dont_need = h->cache_dont_need;
111     pi.lock_manager = std::move(lock_manager);
112 }
113

```

1.1 calc_clone_subsets

用于修复快照对象，在此之前介绍两个概念

1.在SnapSet结构中，字段clone_overlap保存了clone对象和上一次clone对象的重叠部分（没有冲突部分）

```

1 struct SnapSet {
2     snapid_t seq;
3     std::vector<snapid_t> snaps; // descending
4     std::vector<snapid_t> clones; // ascending


```

```

5     std::map<snapid_t, interval_set<uint64_t>> clone_overlap; // overlap w/
    next newest
6     std::map<snapid_t, uint64_t> clone_size;
7     std::map<snapid_t, std::vector<snapid_t>> clone_snaps; // descending
8 }

```

2.clone_overlap



snap3从snap2克隆过来，然后修改了区间3，4，其在对象中范围的offset和length为（4，8），（8，12）那么记录就为：

```
clone_overlap[3] = {(0, 4), (12, len(区间8-区间4))}
```

然后是calc_clone_subsets函数

```

1 void ReplicatedBackend::calc_clone_subsets(
2     SnapSet &snapset, const hobject_t &soid,
3     const pg_missing_t &missing,
4     const hobject_t &last_backfill,
5     interval_set<uint64_t> &data_subset,
6     map<hobject_t, interval_set<uint64_t>> &clone_subsets,
7     ObcLockManager &manager) {
8
9     // 1 获取快照大小，加入到data_subset中（虽然不知道这是在干嘛）
10    uint64_t size = snapset.clone_size[soid.snap];
11    if (size) data_subset.insert(0, size);
12
13    // any overlap with next older clone?
14    interval_set<uint64_t> cloning;
15    interval_set<uint64_t> prev;
16
17    // 2 往前查找完整的快照对象区间，添加到clone_subsets和cloning
18    if (size)
19        prev.insert(0, size);
20    for (int j = i - 1; j >= 0; j--) {
21        hobject_t c = soid;
22        c.snap = snapset.clones[j];
23        // 计算重叠区间

```

```

24     prev.intersection_of(snapset.clone_overlap[snapset.clones[j]]);
25     if (!missing.is_missing(c) &&
26         c < last_backfill &&
27         get_parent()->try_lock_for_read(c, manager)) {
28         clone_subsets[c] = prev;
29         cloning.union_of(prev);
30         break;
31     }
32 }
33
34 // 同上，往后查找
35 // overlap with next newest?
36 interval_set<uint64_t> next;
37 if (size)
38     next.insert(0, size);
39 for (unsigned j = i + 1; j < snapset.clones.size(); j++) {
40     hobject_t c = soid;
41     c.snap = snapset.clones[j];
42     next.intersection_of(snapset.clone_overlap[snapset.clones[j - 1]]);
43     if (!missing.is_missing(c) &&
44         c < last_backfill &&
45         get_parent()->try_lock_for_read(c, manager)) {
46         clone_subsets[c] = next;
47         cloning.union_of(next);
48         break;
49     }
50 }
51 // 去重
52 data_subset.subtract(cloning);
53 }

```

光看代码看不出是在做什么，书上给了一个例子：




图 11-3 快照对象修复计算示例图

snap3是克隆的snap2, snap4 克隆的snap3, snap5克隆的snap4, 灰色区间表示clone后修改的区间, snap2、3、5都是完整的对象, 要修复的对象是snap4, 不同长度代表各个clone对象的size是不同的。

1.向前查找和snap4相同的区间, 可以看到区间1, 5, 8和snap4相同, 那么snap4就直接从本地拿到这三个区间。

2.向后查找, 可以看到1, 2, 3, 4, 7, 8未被修改, 那么直接拿过来就行

3.去重, 最后只有区间6需要从其他OSD上拷贝数据来修复。

2 push

获取actingbackfill的OSD列表, 通过peering_missing查找缺失该对象的OSD, 并发送信息给对方

```
1  int ReplicatedBackend::start_pushes(
2      const hobject_t &soid,
3      ObjectContextRef obc,
4      RPGHandle *h) {
5
6  // 1 用于存储需要数据的OSD
7      list<map<pg_shard_t, pg_missing_t>::const_iterator> shards;
8
9  // 遍历actingbackfill列表, 统计需要信息的OSD
10     ceph_assert(get_parent()->get_acting_recovery_backfill_shards().size() >
11                 0);
12     for (set<pg_shard_t>::iterator i =
13           get_parent()->get_acting_recovery_backfill_shards().begin();
14           i != get_parent()->get_acting_recovery_backfill_shards().end();
15           ++i) {
16         if (*i == get_parent()->whoami_shard())
17             continue;
18         pg_shard_t peer = *i;
19         map<pg_shard_t, pg_missing_t>::const_iterator j =
20             get_parent()->get_shard_missing().find(peer);
21         ceph_assert(j != get_parent()->get_shard_missing().end());
22         if (j->second.is_missing(soid)) {
23             shards.push_back(j);
24         }
25
26         // If more than 1 read will occur ignore possible request to not cache
27         bool cache = shards.size() == 1 ? h->cache_dont_need : false;
28
29     // 发送信息
30     for (auto j : shards) {
31         pg_shard_t peer = j->first;
```



```

32     h->pushes[peer].push_back(PushOp());
33     int r = prep_push_to_replica(obc, soid, peer,
34                                 &(h->pushes[peer].back()), cache);
35     if (r < 0) {
36         // Back out all failed reads
37         for (auto k : shards) {
38             pg_shard_t p = k->first;
39             h->pushes[p].pop_back();
40             if (p == peer)
41                 break;
42         }
43         return r;
44     }
45 }
46 return shards.size();
47 }

```

```

1  int ReplicatedBackend::prep_push_to_replica(
2      ObjectContextRef obc, const hobject_t &soid, pg_shard_t peer,
3      PushOp *pop, bool cache_dont_need) {
4      const object_info_t &oi = obc->obs.oi;
5      uint64_t size = obc->obs.oi.size;
6
7      map<hobject_t, interval_set<uint64_t>> clone_subsets;
8      interval_set<uint64_t> data_subset;
9
10     ObcLockManager lock_manager;
11     // 1 如果对象是一个快照
12     if (soid.snap && soid.snap < CEPH_NOSNAP) {
13         hobject_t head = soid;
14         head.snap = CEPH_NOSNAP;
15
16     // 1.1 尝试基于成功或先于当前快照的克隆来推送数据。这需要在本地获取对象的头部 (head) 和当前
        // 的快照集 (SnapSet)
17         if (get_parent()->get_local_missing().is_missing(head)) {
18             return prep_push(obc, soid, peer, pop, cache_dont_need);
19         }
20     // 1.2 如果head存在，获取克隆数据子集和数据子集，使用这些信息来准备推送操作
21         SnapSetContext *ssc = obc->ssc;
22         ceph_assert(ssc);
23
24         pop->recovery_info.ss = ssc->snapset;
25         map<pg_shard_t, pg_missing_t>::const_iterator pm =

```

```

26         get_parent()->get_shard_missing().find(peer);
27         ceph_assert(pm != get_parent()->get_shard_missing().end());
28         map<pg_shard_t, pg_info_t>::const_iterator pi =
29             get_parent()->get_shard_info().find(peer);
30         ceph_assert(pi != get_parent()->get_shard_info().end());
31         calc_clone_subsets(
32             ssc->snapset, soid,
33             pm->second,
34             pi->second.last_backfill,
35             data_subset, clone_subsets,
36             lock_manager);
37     } else if (soid.snap == CEPH_NOSNAP) {
38 // 2 如果不是快照，同样计算数据集，并使用这些信息来准备推送操作
39         SnapSetContext *ssc = obc->ssc;
40         ceph_assert(ssc);
41
42         calc_head_subsets(
43             obc,
44             ssc->snapset, soid, get_parent()->get_shard_missing().find(peer)-
45             >second,
46             get_parent()->get_shard_info().find(peer)->second.last_backfill,
47             data_subset, clone_subsets,
48             lock_manager);
49     }
50 // 3 构造PushOp
51     return prep_push(
52         obc,           // 对象上下文
53         soid,          // 对象ID
54         peer,          // 目标
55         oi.version,    // 对象版本
56         data_subset,   // 数据子集
57         clone_subsets, // 克隆数据子集
58         pop,           // 推送操作指针
59         cache_dont_need, // 是否需要缓存
60         std::move(lock_manager)); // 锁管理器
61 }
62
63 prep_push:
64 >> int r = build_push_op(pi.recovery_info, pi.recovery_progress, &new_progress,
65     pop, &(pi.stat), cache_dont_need);
66

```

```

1 int ReplicatedBackend::build_push_op(const ObjectRecoveryInfo &recovery_info,
2                                     const ObjectRecoveryProgress &progress,
3                                     ObjectRecoveryProgress *out_progress,

```

```

4             PushOp *out_op,
5             object_stat_sum_t *stat,
6             bool cache_dont_need) {
7     ObjectRecoveryProgress _new_progress;
8     if (!out_progress)
9         out_progress = &_new_progress;
10    ObjectRecoveryProgress &new_progress = *out_progress;
11    new_progress = progress;
12    eversion_t v = recovery_info.version;
13    object_info_t oi;
14
15    // 1 是第一次恢复，需要获取元数据信息
16    if (progress.first) {
17        int r = store->omap_get_header(ch, ghobject_t(recovery_info.soid),
18        &out_op->omap_header);
19
20        r = store->getattrs(ch, ghobject_t(recovery_info.soid), out_op-
21        >attrset);
22
23        // Debug
24        try {
25            oi.decode(out_op->attrset[OI_ATTR]);
26        } catch (...) {
27            return -EINVAL;
28        }
29
30        // If requestor didn't know the version, use ours
31        if (v == eversion_t()) {
32            v = oi.version;
33        } else if (oi.version != v) {
34            return -EINVAL;
35        }
36
37        // 3 标志为false，表示后续请求将包含版本信息
38        new_progress.first = false;
39    }
40
41    // 一旦我们提供了版本，随后的请求就会有它，所以在这一点上它必须是已知的。
42    ceph_assert(v != eversion_t());
43
44    // 4 上一步只获取了header，没有omap(key, value)信息，这一步获取
45    // 首先获取可用的数据块大小
46    uint64_t available = cct->_conf->osd_recovery_max_chunk;
47    if (!progress.omap_complete) {
48        ObjectMap::ObjectMapIterator iter =
49            store->get_omap_iterator(ch,
50            ghobject_t(recovery_info.soid));

```



```

93         if (out_op->data_included.empty() ||
94             out_op->data_included.range_end() == copy_subset.range_end())
95             new_progress.data_recovered_to =
recovery_info.copy_subset.range_end();
96         else
97             new_progress.data_recovered_to = out_op-
>data_included.range_end();
98     }
99     } else {
100         out_op->data_included.clear();
101     }
102
103     auto origin_size = out_op->data_included.size();
104     bufferlist bit;
105 // 6 将数据读入缓冲区bit, 说实话不知道为什么又要将数据转一遍
106     int r = store->readv(ch, ghobject_t(recovery_info.soid),
107                         out_op->data_included, bit,
108                         cache_dont_need ? CEPH_OSD_OP_FLAG_FADVISE_DONTNEED :
0);
109
110     if (cct->_conf->osd_debug_random_push_read_error &&
111         (rand() % (int)(cct->_conf->osd_debug_random_push_read_error * 100.0))
== 0) {
112         r = -EIO;
113     }
114 // 7 数据块大小发生变化
115     if (out_op->data_included.size() != origin_size) {
116         new_progress.data_complete = true;
117     }
118 // 8 将数据追加到out_op->data, 是data_included不能直接追加吗
119     out_op->data.claim_append(bit);
120     // 检验数据完整性, 数据校验和等
121     if (progress.first && !out_op->data_included.empty() &&
122         out_op->data_included.begin().get_start() == 0 &&
123         out_op->data.length() == oi.size && oi.is_data_digest()) {
124         uint32_t crc = out_op->data.crc32c(-1);
125         if (oi.data_digest != crc) {
126             return -EIO;
127         }
128     }
129
130 // 9 恢复进度完成
131     if (new_progress.is_complete(recovery_info)) {
132         new_progress.data_complete = true;
133         if (stat) {
134             stat->num_objects_recovered++;
135             if (get_parent()->pg_is_repair())

```

```

136         stat->num_objects_repaired++;
137     }
138 } else if (progress.first && progress.omap_complete) {
139     new_progress.omap_complete = false;
140 }
141
142 if (stat) {
143     stat->num_keys_recovered += out_op->omap_entries.size();
144     stat->num_bytes_recovered += out_op->data.length();
145     get_parent()->get_logger()->inc(l_osd_rbytes, out_op-
>omap_entries.size() + out_op->data.length());
146 }
147
148 get_parent()->get_logger()->inc(l_osd_push);
149 get_parent()->get_logger()->inc(l_osd_push_outb, out_op->data.length());
150
151 // 10 更新out_op信息，注意out_op其实就是PushOp的引用
152 // send
153 out_op->version = v;
154 out_op->soid = recovery_info.soid;
155 out_op->recovery_info = recovery_info;
156 out_op->after_progress = new_progress;
157 out_op->before_progress = progress;
158 return 0;
159 }

```

run_recovery_op

```

1 void ReplicatedBackend::run_recovery_op(
2     PGBackend::RecoveryHandle *_h,
3     int priority) {
4     RPGHandle *h = static_cast<RPGHandle *>(_h);
5 // 这里的pushes和pulls就是上文中的PushOp和PullOp集合
6     send_pushes(priority, h->pushes);
7     send_pulls(priority, h->pulls);
8     send_recovery_deletes(priority, h->deletes);
9     delete h;
10 }

```

handle_pull

当主OSD将对象推送给从OSD后，从OSD需要调用handle_push来实现数据的写入；同样，当主OSD给从OSD发起拉取请求后，需要handle_pull处理对应的请求。

```

1 void ReplicatedBackend::handle_pull(pg_shard_t peer, PullOp &op, PushOp
  *reply) {
2     const hobject_t &soid = op.soid;
3     struct stat st;
4 // 1 验证对象是否存在
5     int r = store->stat(ch, ghobject_t(soid), &st);
6
7     if (r != 0) {
8 // 不存在返回空值
9         prep_push_op_blank(soid, reply);
10    } else {
11        ObjectRecoveryInfo &recovery_info = op.recovery_info;
12        ObjectRecoveryProgress &progress = op.recovery_progress;
13
14 // 2 第一次修复，且全部拷贝
15        if (progress.first && recovery_info.size == ((uint64_t)-1)) {
16            recovery_info.size = st.st_size;
17            if (st.st_size) {
18                interval_set<uint64_t> object_range;
19                object_range.insert(0, st.st_size);
20                // 添加数据
21                recovery_info.copy_subset.intersection_of(object_range);
22            } else {
23                recovery_info.copy_subset.clear();
24            }
25            assert(recovery_info.clone_subset.empty());
26        }
27 // 3 构建PushOp操作
28        r = build_push_op(recovery_info, progress, 0, reply);
29        if (r < 0) prep_push_op_blank(soid, reply);
30    }
31 }

```

recover_replicas

```

1 uint64_t PrimaryLogPG::recover_replicas(uint64_t max, ThreadPool::TPHandle
  &handle,
2                                     bool *work_started) {
3     uint64_t started = 0;
4
5 // 1 获取一个Handle，用于Push和Pull
6     PGBackend::RecoveryHandle *h = pgbackend->open_recovery_op();
7
8     ceph_assert(!get_acting_recovery_backfill().empty());
9     std::vector<std::pair<unsigned int, pg_shard_t>> replicas_by_num_missing,

```

```

10     async_by_num_missing;
11     replicas_by_num_missing.reserve(get_acting_recovery_backfill().size() - 1);
12 // 2 遍历所有正在修复的OSD
13     for (auto &p : get_acting_recovery_backfill()) {
14         if (p == get_primary()) {
15             continue;
16         }
17         auto pm = recovery_state.get_peer_missing().find(p);
18         ceph_assert(pm != recovery_state.get_peer_missing().end());
19         auto nm = pm->second.num_missing();
20         if (nm != 0) {
21             if (is_async_recovery_target(p)) {
22                 async_by_num_missing.push_back(make_pair(nm, p));
23             } else {
24                 replicas_by_num_missing.push_back(make_pair(nm, p));
25             }
26         }
27     }
28     // 排序函数
29     auto func = [](const std::pair<unsigned int, pg_shard_t> &lhs,
30                   const std::pair<unsigned int, pg_shard_t> &rhs) {
31         return lhs.first < rhs.first;
32     };
33
34 // 3 按缺失数量排序副本，从小到大
35     std::sort(replicas_by_num_missing.begin(), replicas_by_num_missing.end(),
36             func);
37     std::sort(async_by_num_missing.begin(), async_by_num_missing.end(), func);
38     replicas_by_num_missing.insert(replicas_by_num_missing.end(),
39                                   async_by_num_missing.begin(),
40                                   async_by_num_missing.end());
41
42 // 4 遍历副本
43     for (auto &replica : replicas_by_num_missing) {
44         pg_shard_t &peer = replica.second;
45         ceph_assert(peer != get_primary());
46         auto pm = recovery_state.get_peer_missing().find(peer);
47         ceph_assert(pm != recovery_state.get_peer_missing().end());
48         size_t m_sz = pm->second.num_missing();
49
50         // oldest first!
51         const pg_missing_t &m(pm->second);
52
53 // 4.1 遍历副本的缺失对象列表
54     for (map<version_t, hobject_t>::const_iterator p =
55         m.get_rmissing().begin();
56         p != m.get_rmissing().end() && started < max;

```



```

54         ++p) {
55         handle.reset_tp_timeout();
56         const hobject_t soid(p->second);
57
58         if (recovery_state.get_missing_loc().is_unfound(soid)) {
59             continue;
60         }
61
62 // 4.2 对象版本比副本的last_backfill新, 说明数据已经存在副本OSD上了
63         const pg_info_t &pi = recovery_state.get_peer_info(peer);
64         if (soid > pi.last_backfill) {
65             if (!recovering.count(soid)) {
66                 ceph_abort();
67             }
68             continue;
69         }
70
71         if (recovering.count(soid)) {
72             continue;
73         }
74
75 // 4.3 如果对象已被删除, 准备删除操作
76         if (recovery_state.get_missing_loc().is_deleted(soid)) {
77             map<hobject_t, pg_missing_item>::const_iterator r =
78 m.get_items().find(soid);
79             started += prep_object_replica_deletes(soid, r->second.need,
80 h, work_started);
81             continue;
82         }
83
84 // 4.4 如果对象是快照, 并且快照的头部对象也在缺失列表中
85         if (soid.is_snap() &&
86             recovery_state.get_pg_log().get_missing().is_missing(
87                 soid.get_head())) {
88             continue;
89         }
90
91         if (recovery_state.get_pg_log().get_missing().is_missing(soid)) {
92             continue;
93         }
94
95 // 4.5 准备推送
96         map<hobject_t, pg_missing_item>::const_iterator r =
97 m.get_items().find(soid);
98         started += prep_object_replica_pushes(soid, r->second.need, h,
99 work_started);
100         }
101     }

```

```

97
98 // 5 推送
99     pgbackend->run_recovery_op(h, recovery_state.get_recovery_op_priority());
100     return started;
101 }

```

handle_push

```

1 void ReplicatedBackend::handle_push(
2     pg_shard_t from, const PushOp &pop, PushReplyOp *response,
3     ObjectStore::Transaction *t, bool is_repair) {
4     /*
5      从 PushOp 结构体中提取数据和进度信息。
6      first 表示是否是恢复过程的开始。
7      complete 表示数据和对象映射 (omap) 是否已经完全恢复。
8      clear_omap 表示是否需要清除对象映射。
9      data_zeros 是一个区间集合，用于记录数据中的零区间。
10     z_offset 和 z_length 分别表示数据恢复的起始偏移量和长度。
11     */
12     bufferlist data;
13     data = pop.data;
14     bool first = pop.before_progress.first;
15     bool complete = pop.after_progress.data_complete &&
16                     pop.after_progress.omap_complete;
17
18     bool clear_omap = !pop.before_progress.omap_complete;
19     interval_set<uint64_t> data_zeros;
20     uint64_t z_offset = pop.before_progress.data_recovered_to;
21     uint64_t z_length = pop.after_progress.data_recovered_to -
22                         pop.before_progress.data_recovered_to;
23     if (z_length)
24         data_zeros.insert(z_offset, z_length);
25
26     // 1 构造响应对象
27     response->soid = pop.recovery_info.soid;
28
29     // 2 将数据提交给对象存储，应用更新
30     submit_push_data(pop.recovery_info, first, complete,
31                     clear_omap, true, // must be replicate
32                     data_zeros, pop.data_included, data, pop.omap_header,
33                     pop.attrset, pop.omap_entries, t);
34
35     if (complete) {
36         if (is_repair) {
37             get_parent()->inc_osd_stat_repaired();

```

```

37         }
38 // 3 通知父对象本地修复完成
39         get_parent()->on_local_recover(
40             pop.recovery_info.soid,
41             pop.recovery_info,
42             ObjectContextRef(), // ok, is replica
43             false,
44             t);
45     }
46 }

```

Backfill过程

Recovery过程通过日志修复对象，日志无法修复就通过Backfill过程直接拷贝数据。

数据结构

last_backfill 是backfill过程中，修复进程的指针。last_backfill初始化为 MIN对象，用来记录Backfill过程中已修复的对象，last_backfill随着修复的进程不断推进，如果对象小于等于last_backfill，就是已经完成修复的对象，如果对象大于last_backfill，需要进一步判断是否需要修复。

如下，last_backfill从MIN推进，此时obj2对象以及obj1已经修复完成，之后的对象待修复。

Bacakfill对象列表	MIN	obj1(1,0)	obj2(1,1)	obj3(1,4)	obj4(1,5)	obj5(1,
			last_backfill			

```

1 struct BackfillInterval {
2     eversion_t version;
3     std::map<hobject_t, eversion_t> objects;
4     hobject_t begin;
5     hobject_t end;
6 }
7 BackfillInterval backfill_info;
8 std::map<pg_shard_t, BackfillInterval> peer_backfill_info;

```

backfill_info在primary上记录backfill的进度，peer_backfill_info（replica 的 backfill_info的集合）记录其余副本的进度。

earliset_peer_backfill() 和 earlist_backfill()

这两个函数非常像，但是返回结果的含义完全不同：

```
1 hobject_t PrimaryLogPG::earliest_peer_backfill() const {
2     hobject_t e = hobject_t::get_max();
3     for (const pg_shard_t &peer : get_backfill_targets()) {
4         const auto iter = peer_backfill_info.find(peer);
5         ceph_assert(iter != peer_backfill_info.end());
6         e = std::min(e, iter->second.begin);
7     }
8     return e;
9 }
10
11 hobject_t PeeringState::earliest_backfill() const {
12     hobject_t e = hobject_t::get_max();
13     for (const pg_shard_t &bt : get_backfill_targets()) {
14         const pg_info_t &pi = get_peer_info(bt);
15         e = std::min(pi.last_backfill, e);
16     }
17     return e;
18 }
```

带peer的返回的是参与backfill的OSD中，最小的begin值。

而earliest_backfill返回的是参与backfill的OSD中，最小的last_backfill值。

流程

1. 首先，check指向所有副本的earliest_backfill()，然后判断check与primary上backfill_info.begin的大小关系。
 - 1.1 check < backfill_info.begin 判定为多余对象，加入to_move中。
 - 1.2 check >= backfill_info.begin 继续判断是否需要backfill
2. 如果check == backfill_info.begin 且 backfill_info.begin == peer_backfill_info.begin（replica上的对象和primary一致），进一步判断：如果版本号一致则不用backfill；不一致则加入need_ver_targs，表示需要修复。
3. 如果2不成立，表示当前check对象和primary不一致，进一步判断：
 - 3.1 如果replica的last_backfill < backfill_info.begin 表示对象缺失，加入missing_targs；
 - 3.2 如果replica的last_backfill >= backfill_info.begin 表示replica上的该对象已经做过backfill，加入skip_targs跳过对象
4. 更新指针 last_backfill_started = backfill_info.begin; backfill_info.pop_front(); 情况2中涉及到的replica全部更新peer_backfill_info.pop_front();

示例

如下图：每一行是一个BackfillInterval，所有replica的BackfillInterval集合被称为peer_backfill_info。

OSD 0 info.lastbackfill = hobject()	obj4(1,1) pbi[0].begin	obj5(1,4)	obj6(1,10)
OSD 1 info.lastbackfill = hobject()		obj5(1,3) pbi[1].begin	
OSD 2 info.lastbackfill = hobject()	obj4(1,1) pbi[2].begin		obj6(1,4)
OSD 3 info.lastbackfill = obj5		obj5(1,4) 从pbi[3]中剔除	obj6(1,1) pbi[3].begin
OSD 4 info.lastbackfill = hobject()		obj5(1,4) pbi[4].begin	obj6(1,10)
OSD 5 (主)		obj5(1,4) backfill_info.begin	obj6(1,10)

初始时，lastbackfill初始化为hobject()，是个空对象，而last_backfill_started = earliest_backfill() 也是一个空对象

上图中有一个特殊的OSD 3，它可能是之前做过backfill（听起来很怪，但不管出于什么原因，姑且当它backfill的进度目前超过了Primary），此时它的last_backfill并不是MIN对象，而是obj5。

第一次recover_backfill:

check指向earliest_peer_backfill()

首先，发现check（obj4）< backfill_info.begin，说明有冗余对象，查找和check相同的对象：OSD 0和OSD 2，加入to_move队列中准备删除。一直循环查找，直到冗余对象全部加入to_move队列，上图的情况，循环一次即可。

同时，被删除的对象会出队

```
1 peer_backfill_info.pop_front(); // 也就是peer_backfill_info.begin前移
2 last_backfill_started = check
```

OSD 0 info.lastbackfill = hobject()	obj4(1,1)	obj5(1,4) pbi[0].begin	obj6(1,10)
OSD 1 info.lastbackfill = hobject()		obj5(1,3) pbi[1].begin	
OSD 2 info.lastbackfill = hobject()	obj4(1,1)		obj6(1,4) pbi[2].begin
OSD 3 info.lastbackfill = obj5			obj6(1,1) pbi[3].begin
OSD 4 info.lastbackfill = hobject()		obj5(1,4) pbi[4].begin	obj6(1,10)
OSD 5 (主)		obj5(1,4) backfill_info.begin	obj6(1,10)
	last_backfill_started		

第二次循环 check = earliest_peer_backfill() ,此时一定大于等于backfill_info.begin，此时按OSD一个个对比：

1. 对于begin对象等于check对象的OSD: 0, 1, 4。判断版本是否正确

1.1 如果不正确就加入修复队列need_ver_targs

1.2 正确则加入keep_ver_targs，不需要修复

2. 对于begin对象不等于check对象的OSD: 2, 3。根据last_backfill判断其修复进度

2.1 对于OSD 2而言，其last_backfill小于backfill_info.begin，判定为缺失了obj5对象，加入missing列表

2.1 对于OSD 3而言，其last_backfill等于backfill_info.begin，判断其已经做过backfill，加入skip队列

下一步，need_ver_targs和keep_ver_targs中的begin全部前移

```

1 peer_backfill_info.pop_front();
2 last_backfill_started = backfill_info.begin

```

OSD 0 info.lastbackfill = hobject()	obj5(1,4)	obj6(1,10) pbi[0].begin
OSD 1 info.lastbackfill = hobject()	obj5(1,3)	pbi[1].begin
OSD 2 info.lastbackfill = hobject()		obj6(1,4) pbi[2].begin
OSD 3 info.lastbackfill = obj5		obj6(1,1) pbi[3].begin
OSD 4 info.lastbackfill = hobject()	obj5(1,4)	obj6(1,10) pbi[4].begin
OSD 5 (主)	obj5(1,4)	obj6(1,10) backfill_info.begin
	last_backfill_started	

假设最大操作数是1，而刚刚我们循环了两次，第一次找了一列to_move对象，第二次处理了一列obj5对象。

1. 对于to_move对象的处理，不算一次”操作“，因为删除是异步的，且消耗资源较少。
2. 对于obj5，整理出了四种操作类型，分别对应队列：keep_ver_targs, need_ver_targs, skip_targs, missing_targs

每一次循环中，如果本次循环处理的不是to_move，那么会处理需要修复的对象：

```

1 // 构造PushOp做backfill
2 if (!need_ver_targs.empty() || !missing_targs.empty()) {
3     ObjectContextRef obc = get_object_context(backfill_info.begin, false);
4     prep_backfill_object_push(backfill_info.begin, obj_v, obc, all_push, h);
5     ops ++; // 操作数
6 }

```

如果达到最大操作数后退出循环，并首先处理to_move队列，通知replica删除对象

```

1 pg_shard_t peer = to_remove[i].get<2>();

```

```

2 reqs[peer] = new MOSDPGBackfillRemove(spg_t(info.pgid.pgid, peer.shard),
  get_osdmap_epoch());
3 for (auto p : reqs) {
4     osd->send_message_osd_cluster(p.first.osd, p.second, get_osdmap_epoch());
5 }
6 // 通知过后，紧接着将准备好的PushOp发出去
7 pgbackend->run_recovery_op(h, recovery_state.get_recovery_op_priority());

```

完成backfill后，更新replica的last_backfill：

```

1 hobject_t new_last_backfill = recovery_state.earliest_backfill();
2 recovery_state.update_peer_last_backfill(bt, new_last_backfill);

```

第二次recover_backfill

OSD 0 info.lastbackfill = obj5	obj5(1,4)	obj6(1,10) pbi[0].begin
OSD 1 info.lastbackfill = obj5	obj5(1,3)	pbi[1].begin
OSD 2 info.lastbackfill = obj5		obj6(1,4) pbi[2].begin
OSD 3 info.lastbackfill = obj5		obj6(1,1) pbi[3].begin
OSD 4 info.lastbackfill = obj5	obj5(1,4)	obj6(1,10) pbi[4].begin
OSD 5 (主)	obj5(1,4)	obj6(1,10) backfill_info.begin
	last_backfill_started	

此时check = earliest_peer_backfill()等于obj6。和obj5一样的处理思路：

1. 对于和check相等的OSD：0 2 3 4：0，4版本正确，不用修复，2，3版本错误，需要修复

2. 和check不相等的OSD 1（此时它已经是空对象了），判断它的last_backfill < backfill_info.begin，判定为缺失对象，加入missing中。

同样的，它们的begin会再次前移，直到backfill_info为空或者达到最大并发处理数

源码

```
1 uint64_t PrimaryLogPG::recover_backfill(
2     uint64_t max,
3     ThreadPool::TPHandle &handle, bool *work_started) {
4     ceph_assert(!get_backfill_targets().empty());
5
6 // 1 初始化backfill区间
7     // Initialize from prior backfill state
8     if (new_backfill) {
9         // on_activate() was called prior to getting here
10        ceph_assert(last_backfill_started ==
11        recovery_state.earliest_backfill());
12
13        new_backfill = false;
14
15        // initialize BackfillIntervals
16        for (set<pg_shard_t>::const_iterator i =
17        get_backfill_targets().begin();
18        i != get_backfill_targets().end();
19        ++i) {
20            peer_backfill_info[*i].reset(
21                recovery_state.get_peer_info(*i).last_backfill);
22        }
23        backfill_info.reset(last_backfill_started);
24
25        backfills_in_flight.clear();
26        // 保存着需要删除的对象
27        pending_backfill_updates.clear();
28    }
29
30 // 2 更新backfill_info.begin, update_range更新需要进行Backfill操作的对象列表
31 backfill_info.begin = last_backfill_started;
32 update_range(&backfill_info, handle);
33
34 unsigned ops = 0;
35 vector<boost::tuple<hobject_t, eversion_t, pg_shard_t>> to_remove;
36 set<hobject_t> add_to_stat;
37
38 // 3 去掉不需要backfill的区间
39 for (set<pg_shard_t>::const_iterator i = get_backfill_targets().begin();
40 i != get_backfill_targets().end();
```

```

38         ++i) {
39             peer_backfill_info[*i].trim_to(
40                 std::max(
41                     recovery_state.get_peer_info(*i).last_backfill,
42                     last_backfill_started));
43         }
44         backfill_info.trim_to(last_backfill_started);
45
46         PGBackend::RecoveryHandle *h = pgbackend->open_recovery_op();
47         while (ops < max) {
48 // 4 当前区间完成backfill后, 添加新的backfill区间
49             if (backfill_info.begin <= earliest_peer_backfill() &&
50                 !backfill_info.extends_to_end() && backfill_info.empty()) {
51                 hobject_t next = backfill_info.end;
52                 backfill_info.reset(next);
53                 backfill_info.end = hobject_t::get_max();
54                 update_range(&backfill_info, handle);
55                 backfill_info.trim();
56             }
57
58             bool sent_scan = false;
59             for (set<pg_shard_t>::const_iterator i =
60 get_backfill_targets().begin();
61                 i != get_backfill_targets().end();
62                 ++i) {
63                 pg_shard_t bt = *i;
64                 BackfillInterval &pbi = peer_backfill_info[bt];
65 // 5 当前backfillInterval没有需要回填的区间, 对相应副本发起扫描操作, 更新数据
66                 if (pbi.begin <= backfill_info.begin &&
67                     !pbi.extends_to_end() && pbi.empty()) {
68                     epoch_t e = get_osdmap_epoch();
69                     MOSDPGScan *m = new MOSDPGScan(
70                         MOSDPGScan::OP_SCAN_GET_DIGEST, pg_whoami, e,
71                         get_last_peering_reset(),
72                         spg_t(info.pgid.pgid, bt.shard),
73                         pbi.end, hobject_t());
74                     if (cct->_conf->osd_op_queue == "mclock_scheduler") {
75                         /* This guard preserves legacy WeightedPriorityQueue
76 behavior for
77 * now, but should be removed after Reef */
78                         m->set_priority(recovery_state.get_recovery_op_priority());
79                     }
80                     osd->send_message_osd_cluster(bt.osd, m, get_osdmap_epoch());
81                     ceph_assert(waiting_on_backfill.find(bt) ==
82 waiting_on_backfill.end());

```

```

81         waiting_on_backfill.insert(bt);
82         sent_scan = true;
83     }
84 }
85
86     // Count simultaneous scans as a single op and let those complete
87 // 6 获取OSd的对象列表后，对比当前主OSD的对象列表来进行修复
88     if (sent_scan) {
89         ops++;
90         start_recovery_op(hobject_t::get_max()); // XXX: was pbi.end
91         break;
92     }
93
94     if (backfill_info.empty() && all_peer_done()) {
95         break;
96     }
97
98     // Get object within set of peers to operate on and
99     // the set of targets for which that object applies.
100     hobject_t check = earliest_peer_backfill();
101 // 7 check指向当前OSD中最小的需要进行Backfill操作的对象
102     if (check < backfill_info.begin) {
103 // 7.1 冗余对象，加入到to_remove队列中
104         set<pg_shard_t> check_targets;
105         for (set<pg_shard_t>::const_iterator i =
get_backfill_targets().begin();
106             i != get_backfill_targets().end();
107             ++i) {
108             pg_shard_t bt = *i;
109             BackfillInterval &pbi = peer_backfill_info[bt];
110             if (pbi.begin == check)
111                 check_targets.insert(bt);
112         }
113         ceph_assert(!check_targets.empty());
114
115         for (set<pg_shard_t>::iterator i = check_targets.begin();
116             i != check_targets.end();
117             ++i) {
118             pg_shard_t bt = *i;
119             BackfillInterval &pbi = peer_backfill_info[bt];
120             ceph_assert(pbi.begin == check);
121
122             to_remove.push_back(boost::make_tuple(check,
pbi.objects.begin()->second, bt));
123             pbi.pop_front();
124         }
125

```

```

126         last_backfill_started = check;
127     } else {
128 // 7.2 check等于backfill_info.begin, 判断对象是否需要backfill
129         eversion_t &obj_v = backfill_info.objects.begin()->second;
130         vector<pg_shard_t> need_ver_targs, missing_targs, keep_ver_targs,
            skip_targs;
131         for (set<pg_shard_t>::const_iterator i =
            get_backfill_targets().begin();
132             i != get_backfill_targets().end();
133             ++i) {
134             pg_shard_t bt = *i;
135             BackfillInterval &pbi = peer_backfill_info[bt];
136             // Find all check peers that have the wrong version
137             if (check == backfill_info.begin && check == pbi.begin) {
138                 if (pbi.objects.begin()->second != obj_v) {
139                     need_ver_targs.push_back(bt);
140                 } else {
141                     keep_ver_targs.push_back(bt);
142                 }
143             } else {
144                 const pg_info_t &pinfo = recovery_state.get_peer_info(bt);
145                 if (backfill_info.begin > pinfo.last_backfill)
146                     missing_targs.push_back(bt);
147                 else
148                     skip_targs.push_back(bt);
149             }
150         }
151
152         if (!keep_ver_targs.empty()) {
153             // These peers have version obj_v
154             // assert(!waiting_for_degraded_object.count(check));
155         }
156 // 8 对于keep_ver_targs中的OSD, 不需要进行Backfill操作
157 // 对于need_ver_targs和missing_targs中的OSD, 需要进行Backfill操作, 准备PushOp
158         if (!need_ver_targs.empty() || !missing_targs.empty()) {
159             ObjectContextRef obc = get_object_context(backfill_info.begin,
false);
160             ceph_assert(obc);
161             if (obc->get_recovery_read()) {
162                 vector<pg_shard_t> all_push = need_ver_targs;
163                 all_push.insert(all_push.end(), missing_targs.begin(),
missing_targs.end());
164
165                 handle.reset_tp_timeout();
166                 int r = prep_backfill_object_push(backfill_info.begin,
obj_v, obc, all_push, h);
167                 if (r < 0) {

```

```

168             *work_started = true;
169             break;
170         }
171         ops++;
172     } else {
173         *work_started = true;
174         break;
175     }
176 }
177
178     last_backfill_started = backfill_info.begin();
179     add_to_stat.insert(backfill_info.begin());
180     backfill_info.pop_front();
181     vector<pg_shard_t> check_targets = need_ver_targs;
182     check_targets.insert(check_targets.end(), keep_ver_targs.begin(),
keep_ver_targs.end());
183     for (vector<pg_shard_t>::iterator i = check_targets.begin();
184         i != check_targets.end();
185         ++i) {
186         pg_s      hard_t bt = *i;
187         BackfillInterval &pbi = peer_backfill_info[bt];
188         pbi.pop_front();
189     }
190 }
191 }
192
193     for (set<hobject_t>::iterator i = add_to_stat.begin();
194         i != add_to_stat.end();
195         ++i) {
196         ObjectContextRef obc = get_object_context(*i, false);
197         ceph_assert(obc);
198         pg_stat_t stat;
199         add_object_context_to_pg_stat(obc, &stat);
200         pending_backfill_updates[*i] = stat;
201     }
202
203 // 9 冗余对象
204     map<pg_shard_t, MOSDPGBackfillRemove *> reqs;
205     for (unsigned i = 0; i < to_remove.size(); ++i) {
206         handle.reset_tp_timeout();
207         const hobject_t &oid = to_remove[i].get<0>();
208         eversion_t v = to_remove[i].get<1>();
209         pg_shard_t peer = to_remove[i].get<2>();
210         MOSDPGBackfillRemove *m;
211         auto it = reqs.find(peer);
212         if (it != reqs.end()) {
213             m = it->second;

```

```

214     } else {
215         m = reqs[peer] = new MOSDPGBackfillRemove(
216             spg_t(info.pgid.pgid, peer.shard),
217             get_osdmap_epoch());
218         if (cct->_conf->osd_op_queue == "mclock_scheduler") {
219             m->set_priority(recovery_state.get_recovery_op_priority());
220         }
221     }
222     m->ls.push_back(make_pair(oid, v));
223
224     if (oid <= last_backfill_started)
225         pending_backfill_updates[oid]; // add empty stat!
226 }
227 for (auto p : reqs) {
228     osd->send_message_osd_cluster(p.first.osd, p.second,
229     get_osdmap_epoch());
230 }
231 // 10 发送PushOp
232 pgbackend->run_recovery_op(h, recovery_state.get_recovery_op_priority());
233
234 // 11 处理已完成backfill的对象，更新backfill位置和状态
235 hobject_t next_backfill_to_complete = backfills_in_flight.empty() ?
236 backfill_pos : *(backfills_in_flight.begin());
237 hobject_t new_last_backfill = recovery_state.earliest_backfill();
238 for (map<hobject_t, pg_stat_t>::iterator i =
239     pending_backfill_updates.begin();
240     i != pending_backfill_updates.end() &&
241     i->first < next_backfill_to_complete;
242     pending_backfill_updates.erase(i++)) {
243     ceph_assert(i->first > new_last_backfill);
244     recovery_state.update_complete_backfill_object_stats(
245         i->first,
246         i->second);
247     new_last_backfill = i->first;
248 }
249
250 ceph_assert(!pending_backfill_updates.empty() ||
251     new_last_backfill == last_backfill_started);
252 if (pending_backfill_updates.empty() &&
253     backfill_pos.is_max()) {
254     ceph_assert(backfills_in_flight.empty());
255     new_last_backfill = backfill_pos;
256     last_backfill_started = backfill_pos;
257 }
258 // 12 更新各个OSD的backfill位置

```

```

259     for (set<pg_shard_t>::const_iterator i = get_backfill_targets().begin();
260          i != get_backfill_targets().end();
261          ++i) {
262         pg_shard_t bt = *i;
263         const pg_info_t &pinfo = recovery_state.get_peer_info(bt);
264
265         if (new_last_backfill > pinfo.last_backfill) {
266             recovery_state.update_peer_last_backfill(bt, new_last_backfill);
267             epoch_t e = get_osdmap_epoch();
268             MOSDPGBackfill *m = NULL;
269             // 12.1 如果值为MAX, 说明backfill完成, 发送OP_BACKFILL_FINISH
270             if (pinfo.last_backfill.is_max()) {
271                 m = new MOSDPGBackfill(
272                     MOSDPGBackfill::OP_BACKFILL_FINISH,
273                     e,
274                     get_last_peering_reset(),
275                     spg_t(info.pgid.pgid, bt.shard));
276                 // Use default priority here, must match sub_op priority
277                 start_recovery_op(hobject_t::get_max());
278             } else {
279                 // 12.2 否则发送OP_BACKFILL_PROGRESS
280                 m = new MOSDPGBackfill(
281                     MOSDPGBackfill::OP_BACKFILL_PROGRESS,
282                     e,
283                     get_last_peering_reset(),
284                     spg_t(info.pgid.pgid, bt.shard));
285                 // Use default priority here, must match sub_op priority
286             }
287             m->last_backfill = pinfo.last_backfill;
288             m->stats = pinfo.stats;
289
290             if (cct->_conf->osd_op_queue == "mclock_scheduler") {
291                 /* This guard preserves legacy WeightedPriorityQueue behavior
292                  * for
293                  * now, but should be removed after Reef */
294                 m->set_priority(recovery_state.get_recovery_op_priority());
295             }
296             // 12.3 发送消息
297             osd->send_message_osd_cluster(bt.osd, m, get_osdmap_epoch());
298         }
299
300         if (ops)
301             *work_started = true;
302         return ops;
303     }

```

对象排序方法

做backfill时，即使各个OSD中相同版本号不同，也能保证各个OSD内对象的相对顺序一致。

```
1 // 首先对对象计算出对象的唯一hash值
2 // 传入参数中一共就两个成员变量：对象名，快照序号
3 explicit hobject_t(const sobject_t &o) :
4     oid(o.oid), snap(o.snap), max(false), pool(PPOOL_META) {
5     set_hash(std::hash<sobject_t>()(o));
6 }
7
8 namespace std {
9 template<> struct hash<hobject_t> {
10     size_t operator()(const hobject_t &r) const {
11         static rjhash<uint64_t> RJ;
12         return RJ(r.get_hash() ^ r.snap);
13     }
14 };
15 }
16
17 inline uint64_t rjhash64(uint64_t key) {
18     key = (~key) + (key << 21); // key = (key << 21) - key - 1;
19     key = key ^ (key >> 24);
20     key = (key + (key << 3)) + (key << 8); // key * 265
21     key = key ^ (key >> 14);
22     key = (key + (key << 2)) + (key << 4); // key * 21
23     key = key ^ (key >> 28);
24     key = key + (key << 31);
25     return key;
26 }
27
28 // 然后根据hash值，计算出用于排序的序号
29 void build_hash_cache() {
30     nibblewise_key_cache = _reverse_nibbles(hash);
31     hash_reverse_bits = _reverse_bits(hash);
32 }
33
34 uint32_t reverse_bits(uint32_t v) {
35     if (v == 0)
36         return v;
37
38     /* reverse bits
39      * swap odd and even bits
40      */
41     v = ((v >> 1) & 0x55555555) | ((v & 0x55555555) << 1);
42     /* swap consecutive pairs */
```



```

43  v = ((v >> 2) & 0x33333333) | ((v & 0x33333333) << 2);
44  /* swap nibbles ... */
45  v = ((v >> 4) & 0x0F0F0F0F) | ((v & 0x0F0F0F0F) << 4);
46  /* swap bytes */
47  v = ((v >> 8) & 0x00FF00FF) | ((v & 0x00FF00FF) << 8);
48  /* swap 2-byte long pairs */
49  v = ( v >> 16          ) | ( v          << 16);

50  return v;
51 }
52
53 // 对象放入backfill的map中后，根据以下规则排列，一般到reverse_bits就能计算出结果
54 auto operator<=>(const hobject_t &rhs) const noexcept {
55     auto cmp = max <=> rhs.max;          // 比较max与rhs.max，相等返回0，不相等返回比较结果
56     if (cmp != 0) return cmp;             // 不相等返回比较结果
57     cmp = pool <=> rhs.pool;               // 比较pool
58     if (cmp != 0) return cmp;
59     cmp = get_bitwise_key() <=> rhs.get_bitwise_key(); // reverse_bits
60     if (cmp != 0) return cmp;
61     cmp = nspace <=> rhs.nspace;          // 命名空间
62     if (cmp != 0) return cmp;
63     if (!(get_key().empty() && rhs.get_key().empty())) {
64         cmp = get_effective_key() <=> rhs.get_effective_key(); // 自定义key和对象名
65         if (cmp != 0) return cmp;
66     }
67     cmp = oid <=> rhs.oid;                // 对象id
68     if (cmp != 0) return cmp;
69     return snap <=> rhs.snap;             // 快照信息
70 }
71

```

